



下载APP



35 | Borg (二) : 互不“信任”的调度系统

2022-01-10 徐文浩

《大数据经典论文解读》

课程介绍 >



讲述：徐文浩

时长 13:56 大小 12.77M



你好，我是徐文浩。

在上节课里，我们一起学习了 Borg 的整体架构。从架构层面来看，Borg 和其他的 Master-Slave 系统，其实都是类似的。其中比较大的一个挑战，是 Borg 需要管理万级别的机器。虽然 Borg 的 Master 集群，仍然是一个会选举出 master 的 Paxos 实现。但是除了 master 之外的其他副本，也需要去承担和 Borglet 通信的职责，而不仅仅是一个同步数据的副本。不过除此之外，在整体架构上，Borg 就没有太多的特殊之处了。



×

而对于 Borg 来说，真正的挑战还是在对于一个个 Task 的调度上。Borg 需要回答三个问题：



第一个问题是，当一个 Job 被发给 Master 的时候，我们究竟应该把它的 Tasks 调度到集群的哪一台机器上去？

第二个问题是，如果用户提交的 Job，Task 里实际消耗的资源和它申明的资源差异很大怎么办？

第三个问题是，在不同的 Task 之间互相竞争 CPU 资源的情况下，虽然看似 CPU 的利用率很高，会不会所有的资源都用在了上下文的切换上，而不是实际的 Task 的运算上？

那么今天这节课，就是要来回答这三个问题，理解了这三个问题，对于我们理解设计系统的工程实践会很有帮助。

我们设计的系统，不能停留在自己的理论思考之中，还需要考虑实际用户会如何使用我们的系统，把“人”的因素一并考虑进来，才能设计出经得起时间考验的大型系统。

“贪心”的开发者和 Borg

每一个使用 Borg 的开发者，在向 Borg 提交任务的时候，都需要申明任务需要使用的资源。Borg 最多只会为你分配这些资源，如果你申请的资源太少，比如内存不足，导致你的程序运行不下去，那么这个就是你自己的问题了。

那么，作为开发者你会怎么做呢？要是我，那肯定是尽量多申请点资源给自己留一点余量。

大部分情况下，开发者并不会去仔细测试自己的程序到底会使用多少资源，很容易作出“拍脑袋”的决策。而且，一般来说，开发者都会偏向于高估自己所需要使用的资源，这样至少不会出现程序运行出问题的情况。但是，我们使用 Borg 的目的，就是尽量**让机器的使用率高一点**。每个开发者都给自己留点 Buffer，那我们集群的利用率怎么高得起来呢？

所以，面对贪心的都会多给自己申请一点资源的开发者，Borg 是通过这样两个方式，来提升机器的使用率。

第一个办法，是对资源进行“超卖”。

也就是我明明只有 64GB 的内存，但是我允许同时有申明了 80GB 的任务在 Borg 里运行。当然，为了保障所有生产型的任务一定能够正常运行，Borg 并不会对它们进行超卖。但是，对于非生产型的任务，比如离线的数据批处理任务，超卖是没有问题的。大不了，其中有些任务在资源不足的时候，会被挂起，或者调度到其他机器上重新运行，任务完成的时间需要久一点而已。

第二个办法，则是对资源进行动态的“回收”。

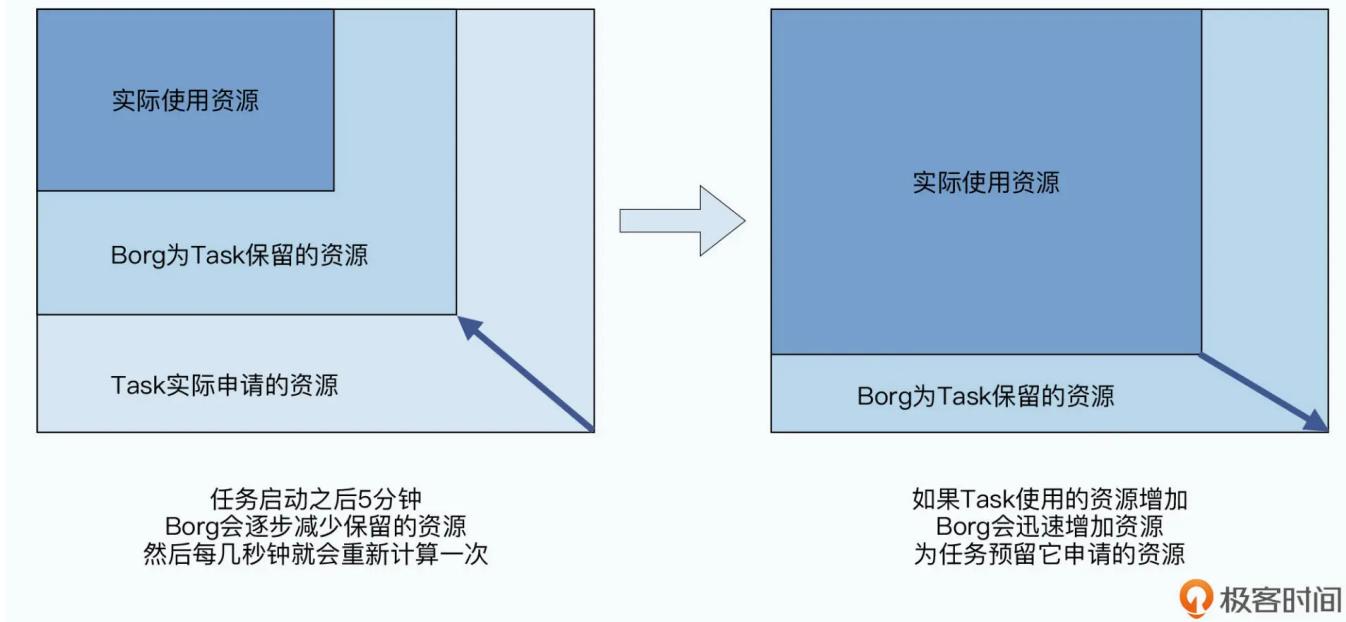
虽然对于非生产的 Job，我们已经采取了超卖的手段。不过，我们所有的生产的 Task，肯定也没有利用满它们所申请的资源。所以，Borg 实际不会为这些 Task 始终预留这么多资源。

Borg 会在 Task 开始的时候，先为它分配它所申请的所有资源。然后，在 Task 成功启动 5 分钟之后，它会慢慢减少给 Task 分配的资源，直到最后变成 Task 当前实际使用的资源，以及 Borg 预留的一些 Buffer。

当然，Task 使用的资源可能是动态变化的。比如一个服务是用来处理图片的，平时都是处理的小图片，内存使用很小，忽然来了一张大图片，那么它使用的内存一下子需要大增。这个时候，Borg 会迅速把 Task 分配的资源，增加到它所申请的资源数量。也就是说，无论是生产型的 Task，还是非生产型的 Task，Borg 实际上都会动态调整分配给它的资源。

我们把开发者申请的资源称之为**限制资源 (Resource Limit)**，而实际 Borg 动态分配给它的则是**保留资源 (Resource Reservation)**，这两者的差值就是我们的**回收资源 (Resource Reclamation)**。这部分回收资源，就是我们可以再利用起来的了。

不过需要注意，这部分资源，Borg 只会分配给非生产型的任务。因为，这部分资源的使用是没有保障的，随时可能因为被回收了资源的生产型 Task，忽然需要资源，被动态地抢回去。如果我们把这部分资源分配给其他生产型的 Task，那么就会面临两个生产型的 Task 抢占资源的问题。而我们在上一讲就说过，Borg 是不允许生产型的 Task 相互抢占的。



从上图中我们可以看到，面对“贪心”的开发者，Borg 采用了所有申请都照章收取的方式。但是在实际分配的过程中，它其实是根据实际情况回收资源，并对资源进行超卖的方式，来提高集群的利用率。在论文的 5.5 部分和图 10 中显示，在 Google 里，20% 的任务是运行在回收而来的资源里的，这就给我们节约了 20% 的机器和相应的电费。可见，这两个策略是相当有效的。

平均分配还是多留点闲人

好了，我们已经了解了 Borg 是怎么通过超卖和回收资源的方式，来提高机器的利用率了。不过，当一个 Task 过来的时候，我们的调度器（Scheduler），应该把它具体分配到这 1 万台服务器里的哪一台服务器上呢？

首先，**Borg 里的调度器和 Master 是分离的**。调度器是异步从 Master 写入的队列里，去扫描有哪些 Task，然后再进行分配的。这个扫描过程中，调度器会先调度高优先级的，再调度低优先级的。而为了保障公平，在同一个优先级里，Borg 会采用**轮询**的方式。

然后，调度的过程分成两步。第一步，我们当然要先保障这个 Task 能正常运行，所以只能寻找哪些服务器能够满足被调度的 Task 的资源需求。这个，被称之为**可行性检查**（feasible checking）。然后是第二步，Borg 会对这个 Task 分配到每一台机器上，去打个分，**根据打分高低来选择一台服务器**。而当资源不足的时候，高优先级的 Task 会抢占掉已经在运行的，低优先级的 Task。

这个时候你可能要问了，我们随便选一台有足够资源的服务器不就行了么，打这么个分数有什么用呢？

那我们就来看看，如果我们随便写个简单的策略，可能会遇到什么情况。

Borg 一开始采用了这样一种策略，它是把每台服务器当前已经分配好的资源计算一个成本 (Cost)。然后呢，模拟把 Task 分配到不同的服务器，再计算一个成本。两个成本之间差值最小的，也就是 Task 分配之后成本变化最小的，就是 Borg 选择的分配方案。

实践下来呢，最终 Task 分配会变成 “**平均分配**” 。也就是，每台服务器的负载都会尽量差不多，类似于一个 “负载均衡” 的方案。但这个问题是，如果我们有一个新的高优先级任务，需要一整台服务器的资源，比如 64 个 CPU、128G 内存。这个时候，我们集群里可能找不出任何一台服务器能有这样的资源。

那么，我们可不可以尽量把现在正在运行的服务器 “塞塞满”，尽量多留出一些空闲的服务器呢？这样，如果有一个需要大量资源的 Task，我们就比较容易找到这样完全空闲的服务器了。

不过，这个策略也有对应的坏处，那就是一旦某个任务需要的资源忽然变多了，就会**抢占**掉同一台机器里面的非生产 Task 的资源。这个时候，那些任务要么得要挂起，要么就得另找机器重新运行了。而且，如果我们的 100 台服务器，10 台是满负载的，90 台是空闲的。一旦我们一台满负载的服务器出现硬件故障，那么对应就有 10% 的任务会受到影响，需要重新调度到其他服务器去。

即使我们的各种应用都做好了容错处理，**容错恢复也需要时间**。这个策略也会放大故障为我们业务带来的风险。

所以，最终 Google 选用了一个混合的模型来打分，也就是**采取尽量减少被“搁浅”(stranded)**的资源数量。所谓被 “搁浅” ，也就是说，当某个任务 100% 占用了自己所申明的资源之后，这个机器上会不能被使用的资源。

事实上，打分需要考虑的因素是很多的，资源分配只是其中的一部分，Borg 里至少还会考虑到下面这些因素：

比如我们应该**尽量挑，对应的机器不需要重新去下载对应 Task 的程序包的机器**。也就是服务器本地已经有了容器镜像的机器。这样，我们就不需要去重新下载 Task 的程序包，可以减少启动所需要的时间。

再比如，我们应该**尽量不要去抢占正在运行 Task 的资源**，如果不得不抢占的话，也尽量挑选抢占得少的机器。因为不是所有被抢占的任务，都是可以先挂起，然后恢复之后继续执行的。很多任务，一旦被抢占了，就执行失败，下次运行又要重新来过。可能看似我们集群的利用率很高，但是都是在做无效劳动。

还有，对于分布式服务的很多个 Task，我们尽量应该让它们**分布到不同的物理位置**，比如不同的机架、交换机等等。这样主要是为了避免，当出现电力故障、网络故障的时候，导致这样的 Job 出现单点故障。

最后，我们应该**让高优先级和低优先级的任务尽量混合部署**。而不是把所有高优先级的 Task 部署在一起，这样我们在负载峰值的时候，就很难让高优先级的任务，去增加自己需要使用的资源。



事实上，在 Borg 之后，Google 开源的 Kubernetes 中，你还可以根据自己的业务特性，去自定义自己的调度器，来满足你自己的需求。

专心致志和多线程工作的差别

可以看到，Borg 对于我们不同类型的任务，其实会采用**混合部署**的模式。也就是一台服务器上，既会有在线的、高优先级、提供服务的生产任务，比如一个 Nginx 反向代理服务器、Kafka 消息队列；也会有离线的、低优先级的批处理任务，比如一个数据分析师提交

的一次性分析任务。而且，我们通常会超卖我们的服务器，我们分配给各个 Task 的资源，也不是完全的 1 个 CPU，而可以是 0.1 个 CPU 这样的细粒度。

这就带来了一个问题，那就是不同的任务之间，其实在竞争相同的 CPU 资源，也会有大量的 CPU 上下文的切换。那么，这个情况是不是会导致，我们集群的利用率看似很高，但是实际上都是浪费在这些上下文切换里呢？这个对我们实际的集群影响会有多大？

说实话，这个问题没有办法得出理论上或者分析上的答案。因为每个 Borg 集群上，运行的任务都不一样，同一个 Borg 集群里，不同时间的负载也不一样，而且同一个集群里，不同的硬件可能也不一样。

不过，Borg 里还是用了一种“从底层解决问题”的方案，那就是直接去测算所有在运行的 Task 的 **CPI** (Cycles Per Instruction)，也就是实际运行的 Task 里，每条 CPU 指令所需要的 CPU 时钟周期。一方面，这个参数隔绝了硬件差异的影响，另一方面，它也直接体现了，我们的 Tasks 运行的实际速度。CPI 大，意味着同样的 Task 需要花更多的时间。

那么，混合部署之后，Borg 上运行任务实际的性能，有没有受到影响呢？

答案是有影响，但是很小，相比于 CPU 利用率的提升，是完全划得来的。在 Borg 的性能评估里，向服务器添加 Task，会让原先的那些 Task 的 CPI 增加 0.3%，可以说忽略不计了。而整体上，CPU 利用率提升 10%，CPI 则只增加了 2%。这也就是说，虽然我们混合部署了更多的任务，的确有了更多的“额外开销 (Overhead)”，但是大部分 CPU 资源，还是用在了新任务的计算上了。

从这个测算 CPI 的评估策略里你可以看到，如果你对计算机底层原理比较熟悉，你就更容易脱离开纷纷扰扰的上层应用系统，直接从底层原理里找到想要的答案。

小结

好了，到这里，对于 Borg 论文的讲解也就完结了。

由于 Borg 系统的用户是千千万万个内部的工程师，所以大有可能每个人都会申请过多的资源。Borg 的解决方案就是会尝试定时回收资源，不断从用户申请使用资源逼近到实际任务真正需要的资源上。

而在分配任务的时候，Borg 采取了一个折中的办法，它既需要考虑尽量让所有服务器的资源使用是平均分配的，使得后续的任务资源的动态扩展有可行性，但又要避免碎片资源太多，任何一台服务器都没有足够的资源，去分配之后出现需要大型资源的任务。而实际要考虑的任务分配因素，还要考虑程序包是否已经下载、同一个 Job 的不同任务是否分配到不同的物理位置，来确保高可用、尽量混合部署等一系列的因素。

最后，Google 还通过 CPI 这个最底层的指标，衡量了混合部署大量应用程序之后的性能影响。我们可以看到，Borg 在混合部署了多种不同的应用之后，CPI 的增加只有 2% 而已。而 CPU 的利用率则大大增加了，可以说是非常划得来了。

并且，Borg 是一个非常面向实战的系统，而不只是局限于理论。这个不仅是 Borg 这个系统的特性，也是我们之前看过的大量大数据系统的共性。

当然，Borg 也并不是完美的，这也是为什么后续 Google 并不是简单地开源了 Borg，而是进一步推出了 Kubernetes。那么，Kubernetes 相较于 Borg，究竟做了哪些改进呢？而 Kubernetes 比起 Borg 是否也还有什么做不到的事情吗？那就请你不要忘了我们下一讲，关于 Kubernetes 的论文解读。

推荐阅读

如果你对 Borg 集群的调度算法感兴趣，那么 Borg 里引用的《[An opportunity cost approach for job assignment in a scalable computing cluster](#)》这篇论文，就很值得一读了。虽然里面的数学公式看起来会有些多，但是通过形式化的方式来思考和设计算法，而不是仅仅凭直觉和经验，会让你对设计出来的系统是否完善，更有信心。

思考题

作为 Kubernetes 的前身，大型集群管理系统，Borg 的论文其实不是一两讲就能全面覆盖的。我们在前面的课程里，也只是主要讲解了 Borg 的系统架构，以及对于资源调度的策略。那么，在读过论文原文之后，你觉得 Borg 里还有哪些值得称道的设计和思考呢？

欢迎在留言区说说你的看法，也欢迎你把今天的内容分享给更多的朋友。

赞 0 提建议

© 版权归极客邦科技所有，未经许可不得传播售卖。页面已增加防盗追踪，如有侵权极客邦将依法追究其法律责任。

上一篇 34 | Borg (一) : 当电力成为成本瓶颈

[更多课程推荐](#)

陈天 · Rust 编程第一课

实战驱动，快速上手 Rust

陈天

Tubi TV 研发副总裁



涨价倒计时 ↗

今日订阅 **¥89**，1月12日涨价至**¥199**

精选留言 (1)

 写留言



barely

2022-01-10

老师，Task 使用的资源可能是动态变化的，是用什么技术动态实现？

